

INTRO A SERIES DE TIEMPO

Prof. Dora Ma
Ballesteros

Septiembre
2026





Series de tiempo

Una serie de tiempo es, formalmente, un conjunto de observaciones registradas en instantes sucesivos, donde el orden temporal es esencial para comprender el comportamiento de la variable estudiada.

El tiempo importa

Ejemplo

Una serie de tiempo nos permite observar cómo evoluciona una variable a través del tiempo.



Ejemplos comunes

- El número diario de casos confirmados de COVID-19.
- La temperatura registrada por hora en una ciudad.
- El precio del dólar minuto a minuto.
- El número de ventas mensuales de un producto.
- Frecuencia cardíaca registrada segundo a segundo por un dispositivo wearable.

Características principales

- Secuencia temporal obligatoria:** no se puede alterar el orden de los registros sin perder información esencial.
- Dependencia entre observaciones:** un valor puede influir sobre los siguientes.
- Contexto histórico:** comprender el pasado es clave para interpretar o predecir el futuro.

¿Para qué sirve?

- Este tipo de información es fundamental para tareas como:
- ✓ **Analizar** patrones.
 - ✓ **Identificar** tendencias.
 - ✓ **Detectar** anomalías.
 - ✓ **Predecir** valores futuros mediante técnicas de pronóstico (*forecasting*).



El análisis de series de tiempo convierte datos en decisiones.



Las series de tiempo poseen características particulares que las diferencian de otros tipos de datos: *secuencia temporal obligatoria*, *dependencia entre observaciones* y *contexto histórico*.



Componentes fundamentales de una Serie de Tiempo

Una serie de tiempo puede analizarse como la combinación de varios componentes que describen distintos tipos de comportamiento temporal.



Identificar estos componentes es clave antes de modelar o realizar pronósticos.


Descomposición aditiva (en este capítulo):

$$y_t = T_t + S_t + C_t + \varepsilon_t$$

y_t : serie observada
 T_t : tendencia
 S_t : estacionalidad
 C_t : ciclo
 ε_t : ruido o componente irregular

Tendencia

Comportamiento global de largo plazo. Indica si la serie crece, decrece o se mantiene estable.



Ejemplo: aumento progresivo del precio de una criptomoneda.

Estacionalidad

Patrones que se repiten cada cierto periodo (días, semanas o meses).



Ejemplo: incremento de ventas en el mes de diciembre.

Ciclo

Fluctuaciones de duración no constante, con inicio y fin impredecibles.



Ejemplo: ciclos de "burbuja" y recesión en un país.

Ruido o irregular

Variaciones aleatorias o perturbaciones imprevistas que no se explican por los otros componentes.



Ejemplo: pico inusual por un evento no previsto.

Serie observada = Tendencia + Estacionalidad + Ciclo + Ruido



Componentes visibles:

- ✓ Tendencia general creciente
- ✓ Patrones que se repiten cada año
- ✓ Fluctuaciones de largo plazo
- ✓ Eventos irregulares



Nota aclaratoria 1

En este capítulo se trabaja bajo el supuesto de una **descomposición aditiva** de la serie de tiempo, una aproximación común en el análisis exploratorio; sin embargo, en aplicaciones reales pueden existir descomposiciones multiplicativas o mixtas.



Nota aclaratoria 2

En este capítulo, el término **estacionariedad** se utiliza en el sentido de **estacionariedad débil** o de **segundo orden**, en la cual la media y la varianza permanecen constantes en el tiempo y la covarianza depende únicamente del retardo temporal.



CLASIFICACIÓN DE SERIES DE TIEMPO

Las series de tiempo pueden clasificarse de distintas formas según la cantidad de variables involucradas, la naturaleza de los datos, su comportamiento estadístico y la regularidad con la que son registradas.

Esta clasificación es importante porque condiciona las técnicas de análisis y los modelos que pueden aplicarse.



Una buena clasificación guía el análisis y mejora la calidad de los modelos y pronósticos.

CLASIFICACIÓN GENERAL



Cada dimensión de clasificación define características propias que determinan el tipo de técnicas y modelos adecuados para su análisis.

Figura 36. Clasificación Series de Tiempo.

SERIES DE TIEMPO DE UNA Y VARIAS VARIABLES

A. Serie de tiempo de una sola variable

Está conformada por una sola variable que se observa a lo largo del tiempo.

Ejemplos: precio diario del dólar, temperatura por hora o cantidad de ventas mensuales.



B. Serie de tiempo multivariada

Está compuesta por dos o más variables observadas simultáneamente en el tiempo.

Ejemplo: costo de apertura y cantidad de transacciones de una criptomoneda (datos por hora).



SERIES CONTINUAS Y DISCRETAS

A. Series continuas

- Toman valores en "cualquier instante" de tiempo.
- Ejemplo: señal de ECG, voltaje eléctrico.



B. Series discretas

- La mayoría de los datasets corresponden a este tipo.
- Registra valores específicos del fenómeno observado, con espaciamentos de minutos, horas o días.



SERIES ESTACIONARIAS Y NO ESTACIONARIAS

A. Serie estacionaria

- Presenta media constante, varianza constante y estructura de correlación estable en el tiempo.
- Muchos modelos estadísticos clásicos asumen estacionariedad.



B. Serie no estacionaria

- Presenta cambios en su media, varianza o estructura de dependencia a lo largo del tiempo.
- La mayoría de las series reales pertenecen a esta categoría y requieren transformaciones.



SERIES REGULARES E IRREGULARES

A. Series regulares

- El espaciamento en tiempo entre registros es fijo.
- Ejemplo: existe un registro cada minuto.



B. Series irregulares

- Los datos no siguen un patrón fijo de tiempo entre observaciones.
- Dificulta su análisis directo y, en muchos casos, exige interpolación o re-muestreo.



¿POR QUÉ ES IMPORTANTE?



Permite entender la naturaleza de los datos.



Guía la selección de técnicas de análisis adecuadas.



Mejora la calidad de los modelos y pronósticos.



Ayuda a tomar mejores decisiones basadas en datos.



Antes de modelar, clasifica correctamente tu serie de tiempo.



La clasificación adecuada de una serie de tiempo es el **primer paso** para un análisis correcto y para construir modelos que realmente capturen el **comportamiento del fenómeno en el tiempo**.



SERIES DE TIEMPO QUE ABORDAREMOS EN ESTE CURSO

Trabajaremos con series de tiempo que son: **no estacionarias**, **discretas**, **multivariadas** y **regulares**.



Estas características definen la naturaleza de los datos con los que trabajaremos y determinan las técnicas y modelos más adecuados para su análisis y pronóstico.



1. NO ESTACIONARIAS

Presentan cambios en su media, varianza o estructura de dependencia a lo largo del tiempo.

Ejemplo:

Costo de apertura de una criptomoneda por hora



La media y/o varianza cambian con el tiempo. Requerirán transformaciones antes del modelamiento.



2. DISCRETAS

Toman valores en instantes de tiempo específicos y separados por intervalos de tiempo.

Ejemplo:

Cantidad de transacciones de una criptomoneda por hora



Observamos y registramos los datos en instantes específicos (por ejemplo, cada hora).



3. MULTIVARIADAS

Están compuestas por dos o más variables observadas simultáneamente en el tiempo.

Ejemplo:

Criptomonedas: costo de apertura y cantidad de transacciones por hora



Analizaremos la relación y dependencia entre múltiples variables a lo largo del tiempo.



4. REGULARES

El espaciamiento entre observaciones es constante o fijo.

Ejemplo:

Datos registrados cada hora sin saltos de tiempo



El intervalo entre observaciones es constante (por ejemplo, 1 hora).



En este curso, trabajaremos con series de tiempo que son:



No estacionarias



Discretas



Multivariadas




Regulares

Comprender y respetar estas características será clave para elegir las técnicas adecuadas y obtener modelos confiables.



AUTOCORRELACIÓN

Mide el grado de relación entre el valor actual de una serie y sus valores pasados desplazados en el tiempo, conocidos como *retardos* o *lags*.



NOS PERMITE RESPONDER PREGUNTAS COMO:



¿El precio de hoy está relacionado con el precio de ayer?




¿Existe relación entre el valor actual y el observado hace un mes?



En series financieras es frecuente encontrar **autocorrelaciones** débiles, inestables y variables en el tiempo, debido a la alta volatilidad y a la influencia de múltiples factores externos. Aun así, estos patrones temporales son fundamentales para el diseño de modelos predictivos.

¿CÓMO SE VISUALIZA?

La herramienta principal para estudiarla es la **función de autocorrelación (ACF)**.



✓ Barras que sobresalen de las líneas punteadas indican autocorrelaciones estadísticamente significativas.

! Valores positivos: relación directa.

- Valores negativos: relación inversa.

¿QUÉ SIGNIFICA?



Autocorrelación positiva (lags bajos): los valores tienden a continuar en la misma dirección.



Autocorrelación negativa: los valores tienden a revertirse.



Sin autocorrelación: los valores pasados no ayudan a predecir el actual.



La autocorrelación suele disminuir a medida que aumenta el lag.

¿POR QUÉ ES IMPORTANTE?



Ayuda a entender la estructura temporal de la serie.



Permite identificar dependencias que pueden aprovecharse para predecir.



Es clave para diagnosticar supuestos de modelos (ej. independencia de residuos).



Guía la elección y el ajuste de modelos (ej. AR, MA, ARIMA).



EN RESUMEN:

La autocorrelación nos revela cuánto “recuerda” el pasado al presente. Conocerla y analizarla es un paso esencial para construir modelos de series de tiempo efectivos.





MEMORIA TEMPORAL

Hace referencia al horizonte de tiempo durante el cual los valores pasados influyen sobre el presente. Dependiendo del fenómeno, una serie puede presentar memoria de distinta duración.



En datos financieros suele predominar una memoria corta, donde los últimos días u horas contienen la mayor parte de la información relevante para la predicción.

TIPOS DE MEMORIA



MEMORIA CORTA

Solo los valores más recientes tienen impacto significativo sobre el presente.



MEMORIA LARGA

Valores antiguos siguen influyendo en el comportamiento actual.



EJEMPLO: SERIE DE PRECIOS DE UNA CRIPTOMONEDA (DATOS DIARIOS)



¿POR QUÉ ES IMPORTANTE?



Determina cuánta información del pasado es útil para predecir el presente.



Guía la elección del número de rezagos (lags) en los modelos.



Afecta la complejidad del modelo: más memoria puede requerir modelos más flexibles.



Ignorar la memoria temporal puede llevar a predicciones inexactas.



EN RESUMEN:

La memoria temporal indica hasta qué punto el pasado es relevante para entender el presente. En muchas series financieras, la memoria corta domina, pero identificar su alcance exacto es clave para construir modelos predictivos efectivos.





DIFERENCIAS ENTRE EL ANÁLISIS EXPLORATORIO CLÁSICO Y EL EDA EN SERIES DE TIEMPO

Ambos buscan comprender, detectar patrones y encontrar anomalías, pero la dimensión temporal introduce retos y técnicas específicas.



En este capítulo trabajamos con datos financieros no estacionarios, lo que refuerza la necesidad de un EDA adaptado a este tipo de señales.

EDA CLÁSICO (DATOS ESTRUCTURADOS)

1 El orden de los datos sí importa



- Las filas pueden reorganizarse sin afectar la interpretación de los resultados.



Reordenar no cambia el análisis

- Reordenar los registros destruye la estructura temporal, impidiendo analizar tendencias, patrones o rupturas.

EDA EN SERIES DE TIEMPO

Ejemplo: Precio de una acción (diario)



- El primer paso del EDA temporal es asegurar que los datos estén correctamente ordenados por fecha y hora.

2 Las visualizaciones se basan en el tiempo



- Predominan histogramas, diagramas de caja y gráficos de barras.



- La herramienta más importante es la gráfica temporal, que permite visualizar:

- ❖ Tendencias
- ❖ Cambios abruptos
- ❖ Periodos de alta volatilidad
- ❖ Comportamientos inusuales

Ejemplo: Precio de una criptomoneda (diario)



- En datos financieros (ej. precios de acciones o criptomonedas), estas curvas son esenciales para identificar patrones reales del mercado.

3 Análisis de estabilidad temporal



- Se evalúan distribuciones completas.



- Se revisa cómo cambian las distribuciones a lo largo del tiempo. Por ejemplo:

- ❖ ¿Aumenta la varianza en ciertos periodos?
- ❖ ¿La volatilidad del precio cambia según el año o el mes?
- ❖ ¿Existen rupturas estructurales evidentes?

Ejemplo: Volatilidad móvil (30 días) de una acción



- Este análisis es especialmente relevante en datos no estacionarios.



EN RESUMEN:

El EDA en series de tiempo reconoce y respeta la dimensión temporal de los datos. Esto permite extraer información más precisa, entender mejor el comportamiento del fenómeno y construir modelos predictivos más efectivos.



4 Uso de estadísticas móviles

En lugar de trabajar con una única media o desviación estándar global, en series de tiempo se emplean promedios móviles, desviaciones móviles y ventanas deslizantes, que permiten estudiar cómo evolucionan estos indicadores en el tiempo.



EN SERIES DE TIEMPO (CIENCIA DE DATOS)

Las estadísticas móviles calculan un promedio (o desviación) usando una ventana deslizante sobre los datos ordenados en el tiempo.




¿CÓMO FUNCIONA?

Para cada instante t , se promedian los últimos k valores (ventana).

Ventana $k = 5$

$$MA_t = \frac{1}{k} \sum_{i=0}^{k-1} x_{t-i}$$

La ventana se desliza y el cálculo se repite.



¿PARA QUÉ SIRVE?

- ✓ Reduce el ruido de la serie.
- ✓ Revela la tendencia subyacente.
- ✓ Ayuda a identificar cambios de nivel o rupturas.
- ✓ Base para construir características para modelos (features).



IDEA CENTRAL:

En ambos casos se promedian valores en una ventana deslizante para eliminar fluctuaciones rápidas (ruido) y resaltar el comportamiento real (tendencia o componente de baja frecuencia).

PUENTE CONCEPTUAL

MISMA IDEA, DIFERENTE CONTEXTO



¿QUÉ LOGRAMOS EN AMBOS CASOS?

- ✓ Suavizar el ruido de alta frecuencia.
- ✓ Resaltar la tendencia o componente lento del comportamiento.
- ✓ Facilitar el análisis, la detección de patrones y la predicción.



La diferencia está en la naturaleza de los datos: valores de un fenómeno a lo largo del tiempo vs. amplitud de una señal a lo largo del tiempo.



EN PDS (FILTRADO DE SEÑALES)

El filtro de promedio (media móvil) promedia muestras consecutivas para suavizar la señal y eliminar componentes de alta frecuencia.




¿CÓMO FUNCIONA?

Para cada muestra n , se promedian las últimas M muestras.

Ventana $M = 5$

$$y[n] = \frac{1}{M} \sum_{i=0}^{M-1} x[n-i]$$

La ventana se desliza muestra a muestra.



¿PARA QUÉ SIRVE?

- ✓ Elimina componentes de alta frecuencia (ruido).
- ✓ Actúa como filtro pasa bajas.
- ✓ Suaviza la señal manteniendo su forma general.
- ✓ Se usa en muchos sistemas de procesamiento de señales.



EQUIVALENCIA:

El promedio móvil en series de tiempo es conceptualmente equivalente al filtro de promedio (media móvil) en PDS.



DIFERENCIAS CLAVE ENTRE EL EDA CLÁSICO Y EL EDA EN SERIES DE TIEMPO

El EDA temporal considera el **ORDEN** y la **EVOLUCIÓN** de los datos en el tiempo.

5 Identificación de dependencias temporales




En el EDA clásico no se consideran relaciones temporales entre registros.
En series de tiempo, es indispensable evaluar cómo los valores pasados influyen en los presentes, a través de:

- ❖ Retardos (*lags*)
- ❖ Ventanas temporales
- ❖ Transformaciones basadas en memoria corta



En este capítulo, esta idea se utilizará para la creación de *features* y no para construir modelos estadísticos clásicos como **ARIMA**.

Ejemplo: efecto de retardos (*lags*)



6 Tratamiento de valores faltantes



En datasets tradicionales se puede imputar con media, mediana o moda sin mayores consecuencias en el orden de los datos. En series de tiempo, la imputación debe preservar el comportamiento temporal, por ejemplo, mediante:

- ❖ Relleno hacia adelante (*forward fill*)
- ❖ Promedios móviles



En datos financieros (ej. donde no se generan observaciones en fines de semana o festivos), es frecuente realizar procesos de re-muestreo en vez de imputación directa.

Ejemplo: imputación respetando el tiempo




El objetivo es preservar la dinámica temporal y evitar distorsionar la evolución de la serie.

7 Enfoque orientado al comportamiento y no a la distribución




El EDA clásico se centra en cómo están distribuidos los valores. El EDA temporal se centra en cómo cambian (evolucionan) esos valores a lo largo del tiempo, lo cual es esencial para comprender fenómenos dinámicos, volátiles y no estacionarios.

EDA CLÁSICO: distribución



EDA TEMPORAL: evolución



Entender el **COMPORTAMIENTO** a lo largo del tiempo permite detectar patrones, tendencias, cambios y rupturas.



EN RESUMEN

Realizar un EDA adecuado en series de tiempo permite construir *features* robustas, detectar patrones clave y preparar la señal para modelos que aprovechan su estructura temporal. Esta preparación es indispensable antes de avanzar hacia los ejemplos prácticos del capítulo.



Datos con fecha/hora



Considerar orden temporal



Analizar comportamiento y dependencias



Crear features temporalmente informativas



¿El dataset COVID19 de la Alcaldía de Bogotá es una Serie de Tiempo?

¿EL DATASET COVID19 DE LA ALCALDÍA DE BOGOTÁ ES UNA SERIE DE TIEMPO?

No. Tiene una columna temporal (fecha), pero eso no lo convierte en una serie de tiempo.



Para que exista una serie de tiempo, necesitamos una variable cuantitativa observada en instantes ordenados en el tiempo, donde el orden temporal tenga significado (una observación por instante t).



DATASET COVID19 ORIGINAL (NO ES SERIE DE TIEMPO)

Cada fila corresponde a un caso individual reportado.
En un mismo día puede haber muchos casos (múltiples filas).

Fecha del reporte	Localidad/Municipio	Estado del caso	Sexo	Edad
10/03/2020	Usaquén	Severo	F	63
10/03/2020	La Calera	Fallecido	M	72
10/03/2020	Suba	Leve	F	29
10/03/2020	Kennedy	Moderado	M	45
10/03/2020	Chapinero	Leve	F	31
...	...	...	...	...
11/03/2020	Engativá	Leve	M	38
11/03/2020	Bosa	Moderado	F	55
11/03/2020	La Calera	Severo	M	67
...	...	...	...	...

¿Por qué NO es una serie de tiempo?

- ✗ La unidad de análisis es el caso (persona).
- ✗ Hay múltiples registros por día (no hay una única observación por instante).
- ✗ Las variables son principalmente categóricas o atributos del caso, no una medida que evoluciona en el tiempo para todos los días.



Este es un dataset estructurado con una variable temporal (fecha), pero no una serie de tiempo.

¿CÓMO OBTENER UNA SERIE DE TIEMPO DE ESTE DATASET?



Agregación por fecha (contar casos)



Transformamos la unidad de análisis: de casos individuales a conteos diarios (una observación por día).



DATASET AGREGADO (SÍ ES SERIE DE TIEMPO)

Ahora tenemos UNA observación por día: el número de casos registrados cada día.

Fecha	Casos diarios (confirmados)
10/03/2020	10
11/03/2020	14
12/03/2020	18
13/03/2020	12
14/03/2020	15
15/03/2020	20
16/03/2020	22
17/03/2020	19
...	...

- ✓ Ahora sí es una serie de tiempo: la variable (casos diarios) evoluciona en el tiempo.

Ejemplo: Serie de casos diarios de COVID19 en Bogotá



¿Por qué SÍ es una serie de tiempo?

- ✓ Una única observación por instante (por día).
- ✓ La variable de interés (casos diarios) cambia en el tiempo.
- ✓ El orden temporal importa para el análisis de tendencias, patrones, estacionalidad, rupturas, etc.

COMPARACIÓN CLAVE



Unidad de análisis: caso (persona).



Múltiples filas por día.



Variables: atributos del caso (categóricas, numéricas).



Preguntas típicas: ¿qué características tienen los casos?, ¿cuántos fallecidos por localidad?, ¿qué grupos de edad fueron más afectados?

DATASET AGREGADO (SÍ ES SERIE DE TIEMPO)



Unidad de análisis: día.



Una sola fila por día.



Variable: medida que evoluciona en el tiempo (casos diarios).



Preguntas típicas: ¿cómo evoluciona el número de casos?, ¿hay tendencia creciente?, ¿cuándo aumentó la velocidad de contagios?, ¿hay patrones semanales o estacionales?

OTROS EJEMPLOS DE SERIES DE TIEMPO DE LA MISMA TEMÁTICA



Casos diarios confirmados



Fallecidos diarios



Pruebas realizadas por día



EN RESUMEN

Tener una columna de fecha no convierte automáticamente un dataset en serie de tiempo.
Necesitamos una medida que se observe a lo largo del tiempo con una única observación por instante.



Casos individuales (múltiples por día)



Agregar por fecha (contar casos)



Serie de tiempo (una por día)



RETO DE CLASE

De datos estructurados a SERIES DE TIEMPO

Transforma el dataset de COVID-19 de la Alcaldía de Bogotá en un dataset de series de tiempo multivariado y realiza un EDA temporal para comprender la evolución de la pandemia.



1 CONSTRUCCIÓN DEL DATASET

El dataset original tiene como unidad de análisis el caso individual:



1 fila = 1 caso



Transforma los datos para obtener:

1 fila = 1 día



La selección de las cuatro series hace parte del reto. Cada grupo decidirá qué variables permiten representar de manera pertinente la evolución de la pandemia y cómo construirlas a partir de los registros originales.

El nuevo dataset debe:

- ✓ Contener mínimo cuatro series de tiempo.
- ✓ Ser multivariado.
- ✓ Contener series discretas.
- ✓ Tener frecuencia regular.
- ✓ Presentar comportamiento no estacionario.



Ejemplo de estructura resultante

Fecha	Casos confirmados	Fallecidos	Casos graves	Recuperados	...
01/04/2020	42	1	6	3	...
02/04/2020	51	2	8	5	...
03/04/2020	47	0	7	9	...
...	...	...	...	...	...

2 EDA DE SERIES DE TIEMPO

Realiza un EDA temporal del dataset construido.

El análisis debe permitir comprender cómo evolucionan las variables y sus relaciones a través del tiempo.


1 Análisis de tendencia por serie

¿Cómo evoluciona cada una de las series de tiempo a lo largo del periodo analizado? Identifica y analiza las principales tendencias, cambios o comportamientos relevantes observados en cada serie.




2 Dependencia entre series de tiempo

¿Qué relaciones existen entre las diferentes series de tiempo construidas? Analiza si los cambios en una serie están relacionados con cambios en las demás y sustenta tus conclusiones con evidencia.



3 Dependencia de valores actuales con pasados

¿En qué medida los valores pasados de cada serie están relacionados con sus valores actuales? Analiza su autocorrelación y memoria temporal e identifica qué retardos (lags) contienen información relevante.



No basta con generar gráficas o calcular estadísticas. Cada resultado utilizado debe estar acompañado de su interpretación.

3 ENTREGABLE



Entrega un EDA de Series de Tiempo acompañado del código en Python utilizado para realizar la transformación y el análisis.

El producto deberá dejar evidencia de tres cosas:



Transformar
cambiar la unidad de análisis y construir las series de tiempo



Analizar
realizar el EDA temporal según las preguntas planteadas



Interpretar
explicar lo que los datos revelan sobre la evolución del fenómeno



Conclusión obligatoria: A partir del EDA realizado, ¿qué aprendieron sobre la evolución de la pandemia que no era evidente cuando analizaron el dataset original como datos estructurados?

4 SOCIALIZACIÓN

Al inicio de la siguiente clase, cada grupo tendrá máximo 5 minutos para presentar:



1 min
Cómo transformaron el dataset y cuáles series construyeron.



3 min
Los hallazgos más importantes del EDA temporal.



1 min
Su principal conclusión.



5 minutos
totales
por grupo.



INICIA EN CLASE,
SE ENTREGA
POSTERIORMENTE



Trabajo en grupo



Entrega: según fecha
definida por el docente



¡Éxitos en el reto!



El análisis temporal revela historias que los datos estructurados no muestran.



RÚBRICA DE EVALUACIÓN

RA 2.1 – Implementa soluciones de ingeniería de datos para datos series de tiempo, integrando procesos de exploración, transformación y análisis sobre un conjunto de datos, utilizando Python y tomando como referencia los casos de estudio desarrollados en la asignatura.



ACCIONES OBSERVABLES	NO CUMPLE (0 puntos)	CUMPLE PARCIALMENTE (0.5 puntos)	CUMPLE POR COMPLETO (1 punto)
1  Transforma el dataset a series de tiempo multivariado. Convierte el dataset estructurado (1 fila = 1 caso) en un dataset de series de tiempo (1 fila = 1 día) con mínimo cuatro series.	● No transforma el dataset o la transformación es incorrecta. ● No garantiza frecuencia regular (hay días faltantes sin tratar). ● No construye mínimo cuatro series en el dataset resultante.	● Transforma parcialmente el dataset, pero la frecuencia no es completamente regular o el tratamiento de faltantes es incompleto. ● Construye cuatro series, pero algunas están mal construidas o poco justificadas.	● Transforma correctamente el dataset a series de tiempo con 1 fila = 1 día. ● Asegura frecuencia regular y distingue adecuadamente entre dato faltante y valor cero. ● Construye mínimo cuatro series bien construidas y justificadas.
2  Analiza la tendencia por serie. Identifica y analiza las principales tendencias, cambios o comportamientos relevantes observados en cada serie.	● No analiza la tendencia de las series o el análisis es inexistente. ● No describe las tendencias, cambios o patrones relevantes. ● No interpreta los resultados obtenidos.	● Analiza la tendencia de manera parcial. ● Describe algunas tendencias, cambios o patrones, pero de forma limitada. ● Interpreta superficialmente los resultados o lo hace de forma incompleta.	● Analiza completamente la tendencia de cada serie. ● Describe con claridad las tendencias, cambios o patrones relevantes. ● Interpreta los resultados de manera pertinente y sustentada.
3  Analiza la dependencia entre series de tiempo. evalúa si los cambios en una serie están relacionados con cambios en las demás y sustenta tus conclusiones con evidencia.	● No analiza la dependencia entre series o el análisis es inexistente. ● No aplica métodos adecuados (correlación, dispersión, etc.). ● No interpreta las relaciones o conclusiones.	● Analiza parcialmente la dependencia entre series. ● Aplica métodos adecuados de forma limitada o con aplicación incompleta. ● Interpreta las relaciones de forma superficial o incompleta.	● Analiza cuidadosamente la dependencia entre las series. ● Aplica métodos adecuados (correlación, dispersión, correlación cruzada, etc.) de manera pertinente. ● Interpreta con claridad las relaciones y sustenta sus conclusiones con evidencia.
4  Analiza la dependencia de valores actuales con pasados. Analiza la autocorrelación y memoria temporal e identifica qué retardos (lags) contienen información relevante.	● No analiza la dependencia temporal o el análisis es inexistente. ● No calcula la autocorrelación o lo hace incorrectamente. ● No identifica los lags relevantes ni los interpreta.	● Analiza parcialmente la dependencia temporal. ● Calcula la autocorrelación o los lags de forma incompleta o con errores. ● Interpreta los lags o la memoria temporal de manera limitada.	● Analiza adecuadamente la dependencia temporal (autocorrelación). ● Calcula correctamente la ACF y otros métodos pertinentes. ● Identifica e interpreta con claridad los lags que contienen información relevante.

ÉXITOS!